

熊伟

Agent 开发工程师 / LLM 应用开发工程师

☎ 18815605340 | ✉ xiongwei990815@163.com | 📍 北京 工作年限: 2.5 年 (2024.02 至今) | 求职意向: Agent 开发工程师 / LLM 应用工程师 / AI 工程化开发工程师

教育背景

伯明翰大学 | 计算机科学 · 硕士 | 2022.09 - 2023.12

合肥工业大学 | 应用化学 · 本科 | 2018.09 - 2022.07

专业技能

熟悉Agent核心运行机制: ReAct闭环、上下文窗口管理、多轮对话状态机、工具调用、Self-Correction (错误回灌+熔断保护) 与Resume/Replay回退策略, 以及Skill沉淀与按需激活机制, 具备系统性分析、调优与决策过程解释能力 具备主流Agent框架源码阅读与架构拆解能力,主导生产级LangChain ReAct Agent系统落地(覆盖Agent Runtime / RAG / 工具权限 / Trace / 评测);了解MCP / A2A等Agent互操作协议及其定位 深入理解LLM Agent、Tool Use、Agent Harness Engineering;熟悉RAG架构及常见优化(Hybrid Search、Query Rewriting、Rerank、多路召回);熟悉Agent记忆系统设计:Episodic / Semantic / Procedural三分法、写入-晋升-召回管线、记忆质量评估与衰减策略;具备Agent可观测性、评估体系、安全权限控制的完整落地经验(append-only Trace + 质量Gate + 三层评测) 端侧落地经验,熟悉AI应用系统后端开发(Python / Kotlin & Java)与API接口设计(FastAPI / 飞书IM多入口),熟悉MySQL / SQLite数据库与数据建模;了解Node.js / Docker;具备量产车机部署经验 熟悉OpenClaw架构与渠道部署, 具备Agent系统从设计、开发、测试到部署交付的全链路落地能力 良好的沟通协作能力,能推动跨团队(算法 / 产品 / 测试 / 车机)技术方案对齐与项目落地

工作经历与项目亮点

理想汽车 | 软件研发工程师 (Android / 环境感知方向) | 北京 | 2024.02 - 至今

- 主导/深度参与 3 个 Agent 系统建设 (车辆软件问题智能诊断 / vla指挥项目 / 任务生成 Agent 评测与调优平台); 承担车载 EID 应用 + Android 智驾交互核心开发
- 参与交付行业首个任意园区无人化接驳 + 首个 L3 智能驾驶交互产品 (vla指挥项目累计 1100w+ 服务 / 月活 90W+ / 月活渗透率 20%+)
- 跨团队协作 (算法 / 产品 / 测试 / 车机), 将大模型驱动能力落地到量产车机

【项目一】车辆软件问题智能诊断 Agent 技术栈: Python / FastAPI / LangChain / OpenAI 兼容 LLM / SQLite / Hybrid Retrieval / YAML 配置驱动

面向车辆软件问题排查场景, 构建基于 LLM 自主规划的 ReAct Agent 系统。系统接收工单输入 (VIN、故障现象、发生时间) 后, 自动采集车云日志、检索代码仓库、进行日志与代码关联分析, 输出**证据-grounded 的结构化根因报告**, 将传统人工排查升级为 Agent 自主规划 + 工具自动执行 + 证据自动关联 + 结论可追溯的智能诊断流程。

- 三层插件化 Agent 架构**: 设计 Domain / Skill / Command-Tool 三层插件化架构, 全部通过声明式 YAML 配置描述能力边界, 新增业务能力无需改动引擎核心代码, 支持多领域 / 多场景 / 多租户扩展。
- ReAct Runtime + 多层护栏 + 工具权限网关**: 实现完整 Reason→Act→Observe 闭环引擎; Runtime 护栏覆盖 Repetition Detection / Periodic Reflection / Turn-Budget Awareness / Self-Correction (error_code 回灌) / 软降级; 通过 planner.approve + allowed_tool_names 白名单 + 路径/biz_type 白名单 + 多级 Filter 拦截工具调用, 权限拒绝结构化回灌 Agent 上下文。
- Hybrid RAG + 经验记忆 + Trace / Resume**: BM25 + 向量混合检索 + Query Rewriting + Metadata Filtering + Top-K Rerank, 历史结论沉淀为可复用经验, 新工单自动召回; append-only investigation_events 真相源 + TraceRecorder 关键事件 + call_id/reply_to 关联 + Checkpoint 快照 + Resume / Replay / failed_replay / initial_state 注入。

量化成果 (占位): 平均排查耗时 [] h | 人工筛查时间下降 []% | 召回命中率 []% | 结论采纳率 []% | Token 消耗下降 []% | Resume 成功率 []% | Domain·Skill·Tool [] 个 | 累计工单 [] 单

【项目二】任务生成 Agent 评测与调优平台 技术栈: Python / FastAPI / LLM-as-a-Judge / MySQL / 异步评测调度 / 自动化回归流水线

围绕自研"任务生成 Agent 服务"搭建评测与调优平台。服务负责将用户自然语言 query 解析为可执行任务，平台通过评测数据驱动 Prompt 迭代与生成流程调优，构建 "评测 → 问题定位 → Prompt / 流程调优 → 回归验证" 的迭代闭环。

- **多维度评测体系 + 三层评测链路**：覆盖任务生成正确性 / 白黑名单合规性 / 多轮上下文一致性 / 拒绝生成合理性 / 误触发控制 / 输出结构稳定性 6 个维度；规则校验（字段完整性 / 枚举值 / 路径合法性）+ LLM-as-a-Judge（语义 / 意图 / 连贯性）+ 人工复核（边界 / 高风险 / 模型不确定 case）三层机制。
- **问题归因 + 回归基线 + 质量 Gate**：评测失败 case 结构化归因到 Prompt 召回 / Prompt 约束 / Agent 流程 / 上下文管理 / 数据 5 类来源，避免盲目调 Prompt；沉淀标准评测用例集作为回归基线；安全 / 拒绝 / 误触发类关键 case 设置强校验，未通过版本不允许上线。
- **评测自动化流水线 + 数据闭环**：定时 / 触发式自动收集输入 / 输出 / 上下文 / 耗时 / 异常并执行规则校验与 LLM 判分，结果落库形成版本级 / 场景级 / 问题类型级数据；与质量看板联动展示达标率 / 失败分布 / 延迟趋势 / 版本对比。

量化成果（占位）：评测集 [] 条 | 业务场景 [] 个 | 迭代轮次 [] 轮 | 达标率 []% → []% | 误触发率下降 []% | 上下文断裂率下降 []% | 回归耗时 [] → [] min | **Gate 拦截问题** [] 个

【项目三】vla指挥项目（语音控车 + 出行规划） 技术栈：Android / Kotlin & Java / Voice SDK（ASR / TTS）/ DDS 通信 / FSD 协议

面向智能驾驶场景的语音控车链路。本人承担**语音模块 ↔ FSD 之间的中间承接层**：承接上游语音模块的意图指令，实现信息透传 → 行为决策 → 指令下发到 FSD，打通"语音 → 自动驾驶"链路，使用户通过自然语言指令即可触发行规划与车辆控制，覆盖行车与泊车两大场景。

- **语音 ↔ FSD 中间承接层 + 多级 Filter 安全门控**：构建 VoiceCopilotRepo / VoiceStore / VoiceReplyBehavior / DDSRepo 模块，承接上游意图 → 信息透传 → 行为决策 → 指令下发给 FSD；VoiceReplyBehavior 内实现多级 Filter（安全 / 冲突 / 无效），行驶中自动禁用高风险功能。
- **二次确认 + 完整行为可解释链路**：高权限指令（漫游 / AVP）实现语音二次确认；所有指令出口（TTS / FSD）由 VoiceReplyBehavior 统一决策便于审计与拦截，类比 Agent 的 Trace 行为审计

量化成果：累计服务 1100w+ 次 | 月活跃用户 90W+ | 月活渗透率 20%+

投递策略

- 投递 **Agent 工程师** 岗位：优先呈现项目一；强调 Domain/Skill/Tool 插件化 + Runtime 护栏 + Hybrid RAG + Trace
- 投递 **AI 平台 / 评测** 岗位：优先呈现项目二；强调 6 维度评测 + 质量 Gate + 调优闭环
- 投递 **智能驾驶 / 车机 Agent 应用** 岗位：优先呈现项目三；强调语音 ↔ FSD 链路承接 + Android 端实现 + 1100w+ 累计服务